
PrzemyslawOlenderPD3

April 13, 2021

```
[1]: import pandas as pd
     import numpy as np
     import seaborn as sns
     import matplotlib.pyplot as plt
     from sklearn.model_selection import train_test_split
     from sklearn.pipeline import Pipeline
     from sklearn.preprocessing import StandardScaler
     from sklearn.model_selection import KFold, cross_validate
[2]: rain_df = pd.read_csv("https://raw.githubusercontent.com/mini-pw/2021L-WUM/main/
      →Prace_domowe/Praca_domowa3/australia.csv")
     rain_df.head()
[2]:
        MinTemp
                 MaxTemp
                          Rainfall Evaporation Sunshine
                                                             WindGustSpeed \
     0
           17.9
                    35.2
                                0.0
                                            12.0
                                                       12.3
                                                                      48.0
                                0.0
     1
           18.4
                    28.9
                                            14.8
                                                       13.0
                                                                      37.0
           19.4
                    37.6
                                0.0
                                            10.8
                                                       10.6
                                                                      46.0
     3
           21.9
                                            11.4
                                                       12.2
                    38.4
                                0.0
                                                                      31.0
           24.2
                    41.0
                                0.0
                                            11.2
                                                        8.4
                                                                      35.0
        WindSpeed9am WindSpeed3pm
                                     Humidity9am
                                                  Humidity3pm Pressure9am
     0
                 6.0
                               20.0
                                            20.0
                                                          13.0
                                                                     1006.3
                19.0
                               19.0
                                            30.0
                                                           8.0
     1
                                                                     1012.9
     2
                30.0
                               15.0
                                            42.0
                                                          22.0
                                                                     1012.3
     3
                 6.0
                                6.0
                                            37.0
                                                          22.0
                                                                     1012.7
                17.0
                               13.0
                                            19.0
                                                          15.0
                                                                     1010.7
        Pressure3pm Cloud9am Cloud3pm
                                         Temp9am
                                                  Temp3pm RainToday
                                                                        RainTomorrow
             1004.4
     0
                           2.0
                                     5.0
                                             26.6
                                                       33.4
                                                                     0
                                                                                    0
     1
             1012.1
                           1.0
                                     1.0
                                             20.3
                                                       27.0
                                                                     0
                                                                                    0
     2
                                             28.7
             1009.2
                           1.0
                                     6.0
                                                       34.9
                                                                     0
                                                                                    0
     3
             1009.1
                           1.0
                                     5.0
                                             29.1
                                                       35.6
                                                                     0
                                                                                    0
             1007.4
                                             33.6
                                                       37.6
                                                                     0
                                                                                    0
                           1.0
                                     6.0
[3]: rain_df.hist(figsize = (18, 12))
     plt.show()
```



Widać dużą dysproporcje miedzy dnami deszczowymi i bezdeszczowymi, uwzględnimy ją przy dzieleniu dancch na zbiory.

0.0.1 Podział na zbiór treningowy i testowy

0.1 Uczenie modeli

```
[6]: split = KFold(n_splits = 10, shuffle =True, random_state = 29)

def results_to_df(results, model):
    data = [
        ['accuracy', np.mean(results['test_accuracy'])],
        ['precision', np.mean(results['test_precision'])],
        ['roc_aux', np.mean(results['test_roc_auc'])],
        ['recall', np.mean(results['test_recall'])]
        ]
        return pd.DataFrame(data, columns = ['measure', model])
```

0.1.1 Regresja liniowa

```
[8]: lr_df
```

```
[8]: measure LogisticRegression
0 accuracy 0.853443
1 precision 0.728115
2 roc_aux 0.884563
3 recall 0.534535
```


0.1.2 Random Forest

[10]: randomForest_df

```
[10]: measure RandomForest
0 accuracy 0.855570
1 precision 0.763147
2 roc_aux 0.887460
3 recall 0.499548
```

0.1.3 K Nearest Neighbors

```
knn_df = results_to_df(knn_results, 'KNeighbours')
[12]: knn_df
[12]:
           measure KNeighbours
          accuracy
                       0.847505
      1 precision
                       0.750117
      2
           roc_aux
                       0.859310
      3
            recall
                       0.461281
     0.2 Ocena modeli
[13]: all_results = pd.merge((pd.merge(lr_df, randomForest_df, on = 'measure')),__
      →knn df, on = 'measure')
      all_results
[13]:
           measure LogisticRegression RandomForest KNeighbours
        accuracy
                              0.853443
                                            0.855570
                                                          0.847505
      1 precision
                              0.728115
                                            0.763147
                                                          0.750117
      2
          roc_aux
                              0.884563
                                            0.887460
                                                          0.859310
      3
            recall
                              0.534535
                                            0.499548
                                                          0.461281
[14]: all_results_melt = all_results.melt(id_vars=['measure'],
                                          value_vars=['LogisticRegression',__
       →'RandomForest', 'KNeighbours'])
      plt.figure(figsize = (9, 6))
      sns.barplot(data = all_results_melt, x = 'variable', y = 'value', hue = variable', y = value', hue
      ).set(xlabel='', ylabel='mean value')
      plt.legend(bbox_to_anchor=(1.01, 1),borderaxespad=0)
      plt.show()
```



Dla każdego z modeli średnie wartośi mair są na podobnym poziomie, więc ciężko wybrać najlepszy s pośród nich.

Accuracy we wszystkich moedlach jest bardzo wysokie, jednak sprawdza ono tylko poprawność odpowiedzi, która należy do zbioru $\{0, 1\}$, przy czym 0 jest znacznie więcej niż 1. Nietrudo więc trafić w większość poprawnych odpowiedzi. Auc_roc daje równie wysokie wyniki.

Porównując Precision i Recall można zauważyć dysproporcje, dni bez deszczu są częściej są uznawane na deszczowe niż dni deszczowe za dni bez deszczu. Te dwie miary razem z accuracy dają dobry obraz działania modelu.