# PD4

May 5, 2021

```
[1]: import pandas as pd
    from sklearn.svm import SVC
    from sklearn.datasets import load_wine
    import dalex
    import numpy as np
    from sklearn.model_selection import train_test_split
    from sklearn.model_selection import RandomizedSearchCV
    from sklearn.preprocessing import StandardScaler
    from sklearn.preprocessing import LabelEncoder
    from sklearn.metrics import accuracy_score
    import warnings
    warnings.filterwarnings('ignore')
```

# 1 Zbiór danych apartments

```
[2]: aparts = dalex.datasets.load_apartments()
    print(aparts.info())
    aparts.head()
```

<class 'pandas.core.frame.DataFrame'>
Int64Index: 1000 entries, 1 to 1000
Data columns (total 6 columns):

#	Column	Non-Null Count	Dtype
0	m2_price	1000 non-null	int64
1	construction_year	1000 non-null	int64
2	surface	1000 non-null	int64
3	floor	1000 non-null	int64
4	no_rooms	1000 non-null	int64
5	district	1000 non-null	object

dtypes: int64(5), object(1) memory usage: 54.7+ KB

None

```
[2]:
        m2_price construction_year surface floor no_rooms
                                                                    district
            5897
                                                                Srodmiescie
     1
                               1953
                                           25
                                                   3
                                                             1
     2
            1818
                               1992
                                          143
                                                   9
                                                             5
                                                                     Bielany
     3
            3643
                               1937
                                           56
                                                   1
                                                             2
                                                                       Praga
                                                   7
     4
            3517
                               1995
                                           93
                                                             3
                                                                      Ochota
     5
            3013
                               1992
                                          144
                                                   6
                                                             5
                                                                     Mokotow
```

## 1.0.1 Encoding i podział na zbiory treningowy i testowy

# 1.0.2 Prosty model bez skalowania

Accuracy score dla prostego modelu bez skalowania i strojenia hiperparametrów wynosi: 0.2166666666666667

## 1.0.3 Strojenie hiperparametrów bez skalowania

```
[24]: model_svc = SVC()

C = [i for i in range(10)]
C.append(20)
C.append(50)

parameters = {
    'C' : C,
    'gamma' : ['scale', 'auto', 3, 10],
    'degree': np.linspace(1, 5, 5)
```

```
svc_rand = RandomizedSearchCV(model_svc, parameters, n_iter=1000, n_jobs=-1)
best_svc = svc_rand.fit(X_train ,y_train)
best_svc.best_estimator_

[24]: SVC(C=1, degree=1.0)

[25]: model_svc = best_svc.best_estimator_
model_svc.fit(X_train, y_train)
y_pred = model_svc.predict(X_test)
```

Accuracy score dla modelu bez skalowania ze strojeniem hiperparametrów wynosi: 0.216666666666667

print('Accuracy score dla modelu bez skalowania ze strojeniem hiperparametrów⊔

## 1.0.4 Skalowanie bez strojenia hiperparametrów

hiper\_model = accuracy\_score(y\_test, y\_pred)

⇔wynosi: ', hiper\_model)

Accuracy score dla prostego modelu ze skalowaniem i bez strojenia hiperparametrów wynosi: 0.31333333333333

### 1.0.5 Strojenie hiperparametrów ze skalowaniem

```
[30]: model_svc = SVC()
svc_rand = RandomizedSearchCV(model_svc, parameters, n_iter=1000, n_jobs=-1)
best_svm = svc_rand.fit(X_train ,y_train)
best_svm.best_estimator_
```

RMSE dla modelu ze skalowaniem i strojeniem hiperparametrów wynosi: 16.54666666666667

#### 1.0.6 Podsumowanie

Skalowanie poprawiło wyniki modelu, za to strojenie hiperparametrów bez skalowania nie poprawiło wyniku, a po skalowaniu nawet pogorszyło, może to wynikać z tego, że RandomizedSearch nie trafił w optymalne rozwiązanie.

# 2 Zbiór danych Wine

## 2.0.1 Prosty model bez skalowania

Accuracy score dla prostego modelu bez skalowania i strojenia hiperparametrów wynosi: 0.5740740740741

### 2.0.2 Strojenie hiperparametrów bez skalowania

[16]: model\_svc = SVC()

parameters = {

```
'C' : [np.linspace(1, 10, 10), 20, 50],
    'gamma' : ['scale', 'auto', 3, 10],
    'degree': np.linspace(1, 5, 5),
    'kernel': ['linear', 'poly', 'rbf']
}

svc_rand = RandomizedSearchCV(model_svc, parameters, n_iter=100)
best_svc = svc_rand.fit(X_train ,y_train)
best_svc.best_estimator_

[16]: SVC(C=20, degree=4.0, gamma=3, kernel='poly')

[17]: model_svc = best_svc.best_estimator_
    model_svc.fit(X_train, y_train)
    y_pred = model_svc.predict(X_test)
hiper_model = accuracy_score(y_test, y_pred)
    print('Accuracy score dla modelu bez skalowania ze strojeniem hiperparametrówu
```

Accuracy score dla modelu bez skalowania ze strojeniem hiperparametrów wynosi: 0.9259259259259

# 2.0.3 Skalowanie bez strojenia hiperparametrów

⇔wynosi: ', hiper\_model)

```
[18]: scaler = StandardScaler()
X_train = scaler.fit_transform(X_train)
X_test = scaler.fit_transform(X_test)

model_svc = SVC(random_state=29)

model_svc.fit(X_train, y_train)
y_pred = model_svc.predict(X_test)

scal_model = accuracy_score(y_test, y_pred)
```

```
print('Accuracy score dla prostego modelu ze skalowaniem i bez strojenia⊔ ⇔hiperparametrów wynosi: ', scal_model)
```

Accuracy score dla prostego modelu ze skalowaniem i bez strojenia hiperparametrów wynosi: 0.9814814814815

## 2.0.4 Strojenie hiperparametrów ze skalowaniem

Accuracy score dla modelu ze skalowaniem i strojeniem hiperparametrów wynosi: 0.9259259259259

#### 2.0.5 Podsumowanie

Skalowanie sprawiło, że model ma prawie 98% poprawności, jednak stojenie hiperparametrów nie poprawiło wyników.