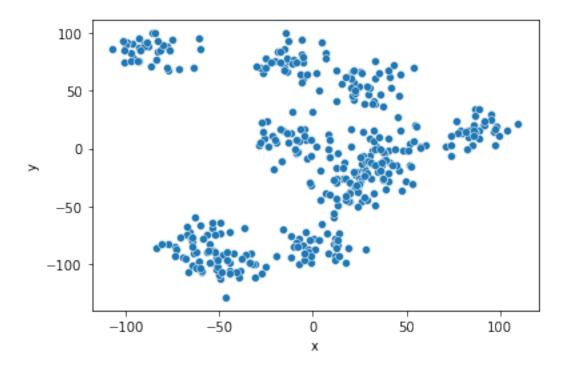
PD5

May 29, 2021

1 Jan Smoleń PD 5

```
[16]: from sklearn.decomposition import PCA
      import pandas as pd
      import numpy as np
      from matplotlib import pyplot as plt
      import seaborn as sns
      import pandas_profiling
      import copy
      from sklearn.decomposition import PCA
      import sklearn.metrics
      from sklearn import manifold
      from sklearn.cluster import KMeans
      from sklearn.manifold import TSNE
      from sklearn.metrics import silhouette_score
 [9]: df=pd.read_csv("clustering.csv", header=None)
[11]: df.columns=["x", "y"]
[13]: sns.scatterplot(df["x"], df["y"], marker = 'o')
     C:\Users\Jan\anaconda3\lib\site-packages\seaborn\_decorators.py:36:
     FutureWarning: Pass the following variables as keyword args: x, y. From version
     0.12, the only valid positional argument will be `data`, and passing other
     arguments without an explicit keyword will result in an error or
     misinterpretation.
       warnings.warn(
[13]: <AxesSubplot:xlabel='x', ylabel='y'>
```



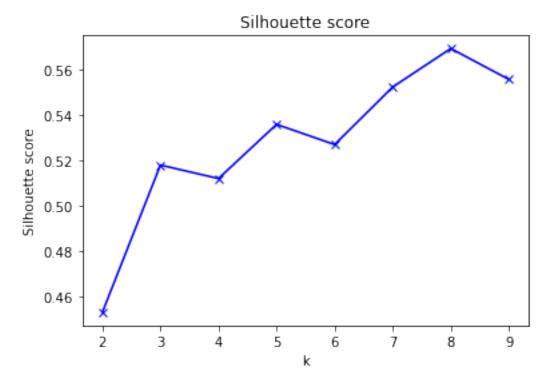
1.1 K-means

```
[14]: def count_clustering_scores(X, cluster_num, model, score_fum):
    if isinstance(cluster_num, int):
        cluster_num_iter = [cluster_num]
    else:
        cluster_num_iter = cluster_num

scores = []
    for k in cluster_num_iter:
        model_instance = model(n_clusters=k)
        labels = model_instance.fit_predict(X)
        wcss = score_fun(X, labels)
        scores.append(wcss)

if isinstance(cluster_num, int):
        return scores[0]
    else:
        return scores
```

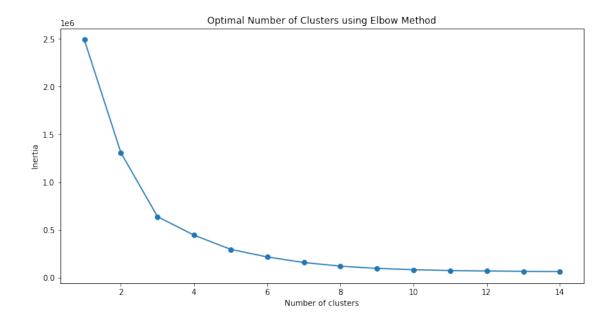
```
plt.xlabel('k')
plt.ylabel('Silhouette score')
plt.title("Silhouette score")
plt.show()
```



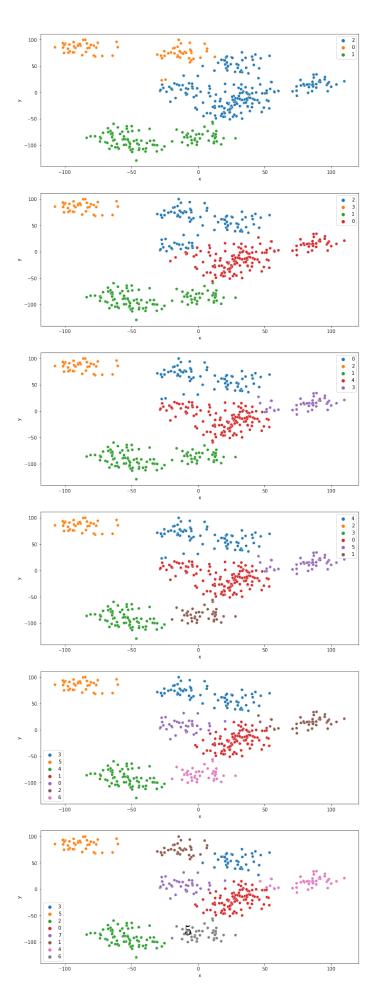
```
[19]: sse = []
k_list = range(1, 15)
for k in k_list:
    km = KMeans(n_clusters=k)
    km.fit(df)
    sse.append([k, km.inertia_])

oca_results_scale = pd.DataFrame({'Cluster': range(1,15), 'SSE': sse})
plt.figure(figsize=(12,6))
plt.plot(pd.DataFrame(sse)[0], pd.DataFrame(sse)[1], marker='o')
plt.title('Optimal Number of Clusters using Elbow Method')
plt.xlabel('Number of clusters')
plt.ylabel('Inertia')
```

[19]: Text(0, 0.5, 'Inertia')



```
fig, axs = plt.subplots(ncols=1, nrows=6, figsize=(12, 36))
rng=range(3, 9)
c=0
lst=[]
for i in rng:
    km=KMeans(n_clusters=i)
    labs=km.fit_predict(df)
    lst=[]
    for i in range(len(labs)):
        lst.append(str(labs[i]))
    sns.scatterplot(data=df, x="x", y="y", marker = 'o', hue=lst, ax=axs[c])
    c+=1
```



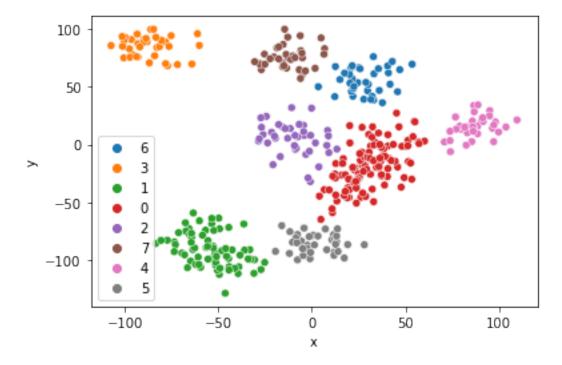
Ciężko wybrać optymalną liczbę klastrów, szczególnie w takim abstrakcyjnym przypadku gdy nie znamy natury problemu. Dwie najlepsze opcje wg mnie to 3 i 8 - 3 ze względu na metode łokcia, a 8 ze wzg na wysokie silhoutte score.

1.2 Klastrowanie hierarchiczne

```
[36]: from sklearn.cluster import AgglomerativeClustering

model = AgglomerativeClustering(n_clusters=8)
labs = model.fit_predict(df)
lst=[]
for i in range(len(labs)):
    lst.append(str(labs[i]))
sns.scatterplot(data=df, x="x", y="y", marker = 'o', hue=lst)
```

[36]: <AxesSubplot:xlabel='x', ylabel='y'>



Patrząc na wyniki klastrowania hierarchicznego dla k=8 widać pewne różnice w porównaniu do klastrowania k-means. Najlepszy przykład to punkty pomiędzy klastrem 0 i 4 (czerwonym i różowym). Zgodnie z intuicją dot. działania obydwu algorytmów, w klastrowaniu hierarchicznym klaster 4 jest bardziej 'zbity'. Natomiast w klastrowaniu k-means jeszcze skrajne punkty leżące w 'chmurze' klastra 0 zostały zaklasyfikowane do klastra 4. Biorąc to pod uwagę, w tym przypadku klastrowanie hierarchiczne wydaje się działać lepiej.