

## PD6

June 16, 2021

```
[1]: from sklearn.datasets import fetch_olivetti_faces
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from matplotlib import cm
```


```
[2]: from numpy.random import RandomState

def plot_gallery(title, images, n_col=3, n_row=2, cmap=plt.cm.gray,
    ↪img_shape=(64,64)):
    plt.figure(figsize=(2. * n_col, 2.26 * n_row))
    plt.suptitle(title, size=16)
    for i, comp in enumerate(images):
        plt.subplot(n_row, n_col, i + 1)
        vmax = max(comp.max(), -comp.min())
        plt.imshow(comp.reshape(img_shape), cmap=cmap,
            interpolation='nearest',
            vmin=-vmax, vmax=vmax)
        plt.xticks(())
        plt.yticks(())
    plt.subplots_adjust(0.01, 0.05, 0.99, 0.93, 0.04, 0.)

faces, _ = fetch_olivetti_faces(return_X_y=True, shuffle=True,
    random_state=RandomState(0))
```

```
[3]: from sklearn.decomposition import PCA

faces, _ = fetch_olivetti_faces(return_X_y=True, shuffle=True)
pca = PCA().fit(faces)
plt.plot(range(1, len(pca.explained_variance_ratio_)+1), np.cumsum(pca.
    ↪explained_variance_ratio_))
plt.xlabel('number of components')
plt.ylabel('cumulative explained variance')
plt.title("PCA explained variance")
plt.axhline(y=0.90, color="y")
plt.axvline(x=70, color="r")
plt.show()
```



Zastosuję PCA dla 70 komponentów, ponieważ osiągnę wówczas około 90% wyjaśnialnej wariancji.

```
[4]: pca = PCA(n_components=70)
      faces_pca = pca.fit_transform(faces)

      print(f"Stopień konwersji: {faces[0].size / faces_pca[0].size}")
      IT = pca.inverse_transform(faces_pca)
```


Stopień konwersji: 58.51428571428571

```
[5]: plot_gallery("Random Olivetti faces", faces[:10], n_col = 5, n_row=2)
      plot_gallery("Random Olivetti faces after PCA and Inverse Transformation", IT[:
      ↪10], n_col = 5, n_row=2)
```

Random Olivetti faces



Random Olivetti faces after PCA and Inverse Transformation



```
[6]: from sklearn.metrics import mean_squared_error

def RMSE(mod):
    rmse = [0] * 400
    for i, j, k in zip(faces, mod, range(400)):
        rmse[k] = mean_squared_error(i, j, squared=False)

    print(f"Średni błąd RMSE: {np.mean(rmse)}")

RMSE(IT)
```

Średni błąd RMSE: 0.042291391640901566

```
[7]: # zamiana koloru
faces_minus = - faces

plot_gallery("Random Olivetti faces", faces_minus[:10], n_col = 5, n_row=2)
RMSE(faces_minus)
```


Uśredniony błąd RMSE: 1.1400033235549927



```
[8]: # Odwrocone do góry nogami
faces_flip = []

for i in faces: faces_flip.append(i[::-1])
plot_gallery("Random Olivetti faces", faces_flip[:10], n_col = 5, n_row=2)
RMSE(faces_flip)
```

Uśredniony błąd RMSE: 0.22976413369178772



```
[9]: # Zwiększony kontrast
faces_mul = 10 * faces

plot_gallery("Random Olivetti faces", faces_mul[:10], n_col = 5, n_row=2)
RMSE(faces_mul)
```

Uśredniony błąd RMSE: 5.130014419555664




```
[10]: # Przyciemnienie
faces_dark = faces - 2

plot_gallery("Random Olivetti faces", faces_dark[:10], n_col = 5, n_row=2)
RMSE(faces_dark)
```

Uśredniony błąd RMSE: 2.0

Random Olivetti faces



```
[11]: # Rozjasnianie
faces_light = faces + 2

plot_gallery("Random Olivetti faces", faces_light[:10], n_col = 5, n_row=2)
RMSE(faces_light)
```

Uśredniony błąd RMSE: 2.0

Random Olivetti faces



Wnioski: Najmniejszy błąd RMSE osiągnęły zdjęcia po transformacji odwrotnej. Mimo znaczącego stopnia kompresji, nie były one dużo bardziej rozmazane. Osoby na tych zdjęciach miały obwódki wokół oczu, jakby okulary.