eksploracja_danych

March 28, 2021

Wpierw załączmy paczki i wczytajmy dane

[6]: import pandas as pd

```
import numpy as np
      from sklearn.datasets import load_boston
      from sklearn.linear_model import LinearRegression, Lasso
      from sklearn.metrics import mean_squared_error
      from sklearn.compose import ColumnTransformer
      from sklearn.preprocessing import FunctionTransformer
      from sklearn.pipeline import Pipeline
      from sklearn.model_selection import train_test_split
      from matplotlib import pyplot as plt
      import seaborn as sns
      from scipy import stats
      import matplotlib.image as mpimg
 [3]: df = pd.DataFrame(pd.read_json("https://api.apispreadsheets.com/api/dataset/
      orient = 'split'))
     Sprawdźmy następnie jakie kolumny ma zbió© danych
[11]: df.columns
[11]: Index(['handicapped_infants', 'water_project_cost_sharing',
             'adoption_of_the_budget_resolution', 'physician_fee_freeze',
             'el_salvador_aid', 'religious_groups_in_schools',
             'anti_satellite_test_ban', 'aid_to_nicaraguan_contras', 'mx_missile',
             'immigration', 'synfuels_corporation_cutback', 'education_spending',
             'superfund_right_to_sue', 'crime', 'duty_free_exports',
             'export_administration_act_south_africa', 'political_party'],
            dtype='object')
     i przystąpmy do zautomatyzowanej eksploracji
 [5]: from pandas_profiling import ProfileReport
```

```
[7]: profile = ProfileReport( df, title="Pandas Profiling Report")

[8]: profile.to_notebook_iframe()

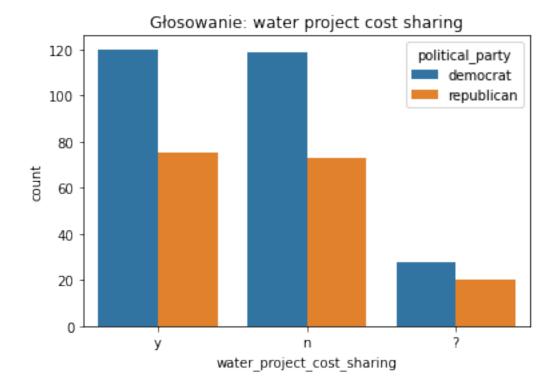
Summarize dataset: 0%| | 0/30 [00:00<?, ?it/s]

Generate report structure: 0%| | 0/1 [00:00<?, ?it/s]
```

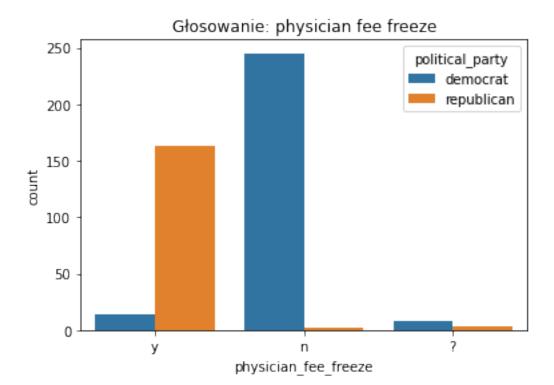
Render HTML: 0% | 0/1 [00:00<?, ?it/s]

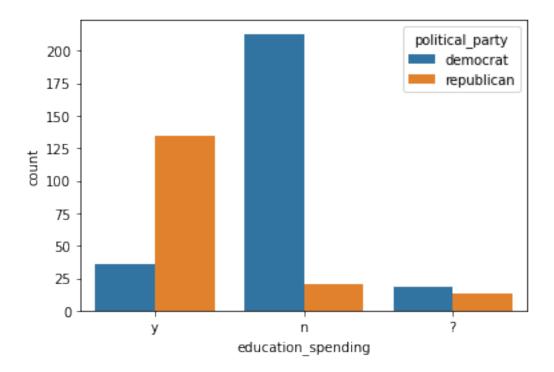
<IPython.core.display.HTML object>

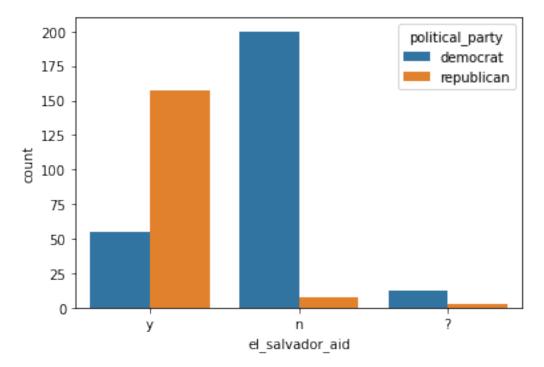
Wpierw zauważmy, ze bywają głosowania, w których głosy są idealnie podzielone 50/50 wewnątrz poszczególnych partii

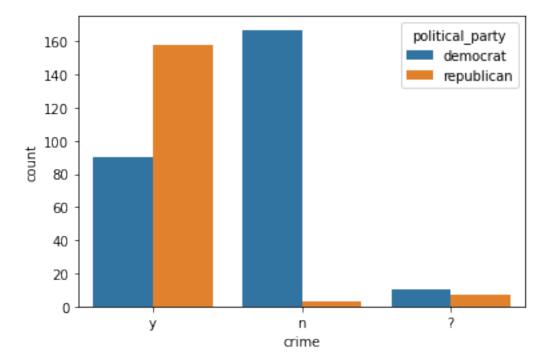


Następnie zauważmy, ze wiele głosowań miało charakter taki, że prawie wszyscy republikanie byli na tak, a demokraci, w większości, na nie



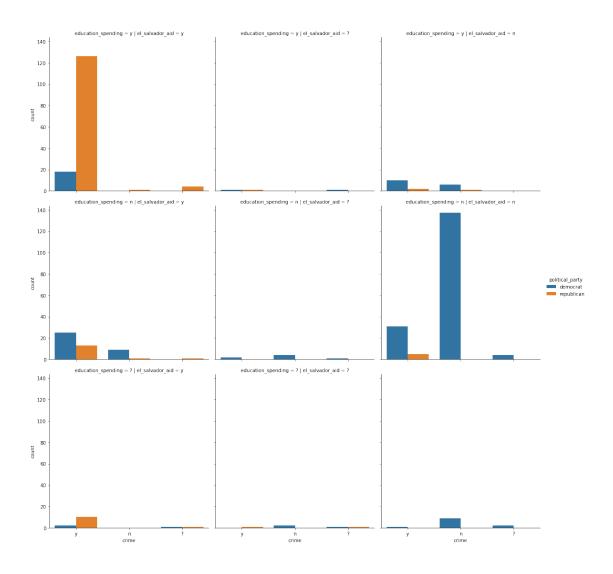






I przejdźmy do zbadania rozkładu (histogramowego) łącznego 3 z badanych głosowań

<Figure size 432x288 with 0 Axes>



Pozwalają one zauważyć mocne odseparowanie partii na podstawie głosowań.

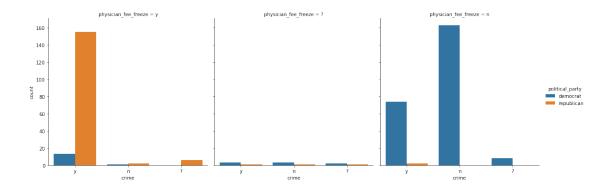
```
[62]: sns.catplot( data = df, x="crime", hue="political_party",⊔

col="physician_fee_freeze",

hue_order=["democrat", "republican"], kind="count",

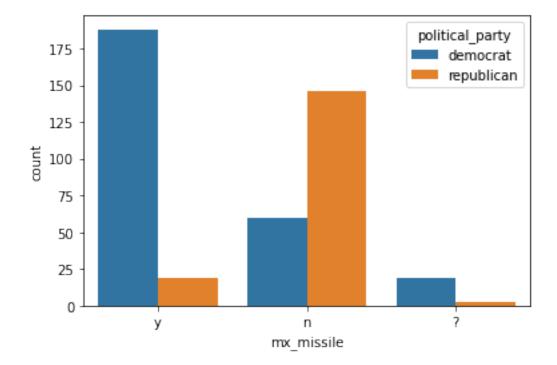
order=["y", "n", "?"])

plt.show()
```



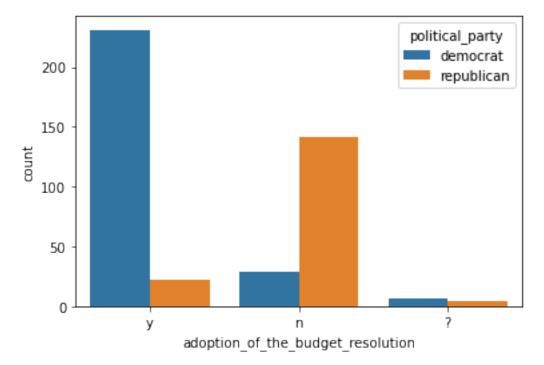
[]:

Następnie, zwróćmy uwagę na zestaw głosowań, w których to demokraci w większości głosowali na tak, a republikanie na nie. Tutaj odseparowanie partii nie jest aż tak silne

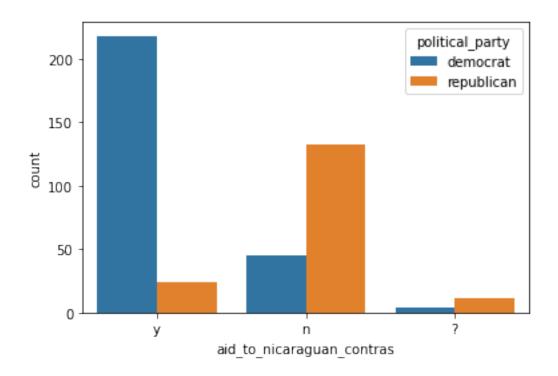


```
[47]: sns.countplot( data = df, x="adoption_of_the_budget_resolution", ⊔

⇔hue="political_party",
```



```
[49]: sns.countplot( data = df, x="aid_to_nicaraguan_contras", hue="political_party", hue_order=["democrat", "republican"], order=["y", "n", "?"]) plt.show()
```



```
[60]: sns.catplot( data = df, x="mx_missile", hue="political_party",

→col="adoption_of_the_budget_resolution",

hue_order=["democrat", "republican"], kind="count",

order=["y", "n", "?"])

plt.show()

adoption_of_the_budget_resolution = 7

adoption_of_the_budget_resolution = 7

political_party

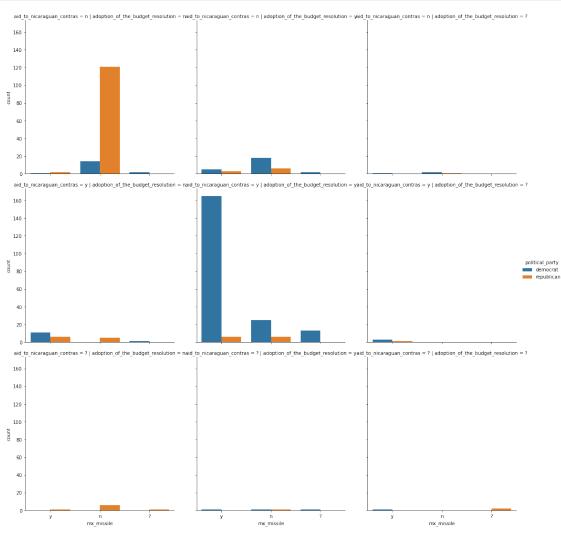
adoption_of_the_budget_resolution = 7

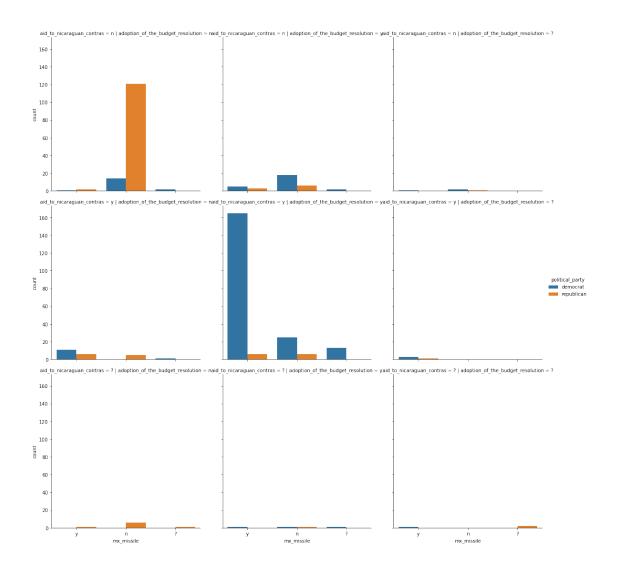
political_party

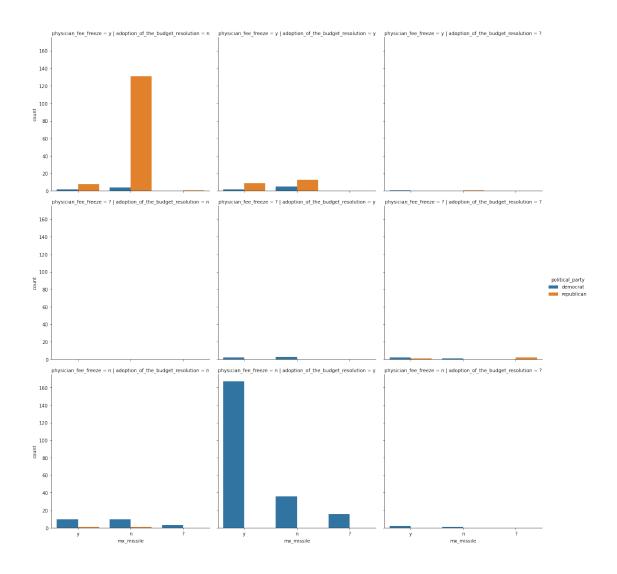
order=["y", "n", "?"])
```

choć odseparowanie partii nie było aż tak silne w rozważanych głosowaniach, zbadanie rozkładu łącznego ułatwia rozdzielenie partii.

```
[65]: sns.catplot( data = df, x="mx_missile", hue="political_party", col="adoption_of_the_budget_resolution", row = □ 
→"aid_to_nicaraguan_contras",
```







Ostatecznie spójrzmy na zestawy danych, które najmniej rozdzielają partie

