Sheet

Raport

Podczas tego projektu zajmowaliśmy się problemem klasteryzacji danych dotyczących ksiąg religijnych. Dane są dostępne pod adresem:https://archive.ics.uci.edu/ml/datasets/A+study+of++Asian+Religious+and+Biblical+Texts . Nasz zbiór składał się z 590 wierszy i 8266 kolumn. Każdy wiersz odpowiadał jednemu rozdziałowi jeden z ksiąg, a kolumny odpowiadały słowom wybranym przez autorów zbioru. W każdej komórce znajdowała się liczba całkowita odpowiadająca liczbie wystąpień danego słowa.

EDA

Pierwszym etapem projektu było EDA, w którym przyjrzeliśmy się bliżej informacjom zawartym w danych.

```
import pandas as pd
import numpy as np
import seaborn as sns
import pandas as pd
from IPython.display import display
import nltk
import warnings
warnings.filterwarnings("ignore")
allBooks = pd.read_csv("AllBooks_baseline_DTM_Unlabelled.csv").rename(columns={'# foolishness': 'fool
allBooks.head()
```

	foolishness	hath	wholesome	takest	feelings	anger	vaivaswata	matrix	kindled	convict	...	erred	thinkest	modern	reigned	sparin
0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0
1	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0
2	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0
3	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0
4	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0

5 rows × 8266 columns

Zdecydowaliśmy się zaprezentować nasze dane w postaci chmury słów. Na takim wykresie wielkość słowa określona jest przez liczbę wystąpień w zbiorze.

```
def word_cloud(x):
    if x == -1:
        x1 = allBooks.mean().sort_values(ascending = False).rename_axis('words').reset_index(name='co
    else:
        x1 = allBooks.loc[x].sort_values(ascending = False).rename_axis('words').reset_index(name='co
    d = {}
    for a, i in x1.values:
        d[a] = i

    import matplotlib.pyplot as plt
    from wordcloud import WordCloud

    wordcloud = WordCloud(background_color="white")
    wordcloud.generate_from_frequencies(frequencies=d)
    plt.figure(figsize = (10,8))
    plt.imshow(wordcloud, interpolation="bilinear")
    plt.axis("off")
    plt.show()
```

```
word_cloud(-1)
```

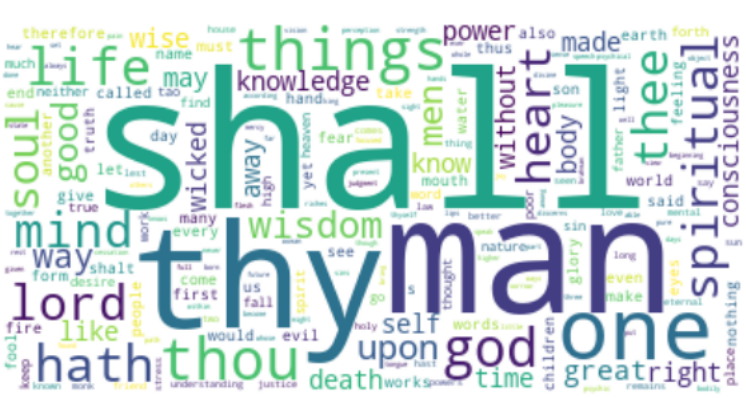


```
word_cloud(0)
```

Powyższe wizualiazje dotyczą: pierwsza wszystkich wierszy w zbiorze, druga tylko pierwszego wiersza.

Chmury słów oprócz wizualnego przedstawienia danych, pomogły nam zauważyć problem z występowaniem tych samych słów w różnych formach. Dlatego w kolejnym etapie czyli preprocessingu skorzystaliśmy z lematyzacji aby ujednolicić formy słów i jednocześnie doprowadzić do zmniejszenia wymiarów.

Preprocessing

W tym kroku zajęliśmy się czyszczeniem naszej ramki danych i przygotowaniem jej do późniejszego modelowania.

Kroki które podjeliśmy w celu zmniejszenia wymiarowości danych to: usunięcie stop words i stemming. Stop wordy są najpopularniejsze słowa takie jak 'and', 'the', 'a',które nie są istotne do analizy,a które mogą zaburzyć modelowanie wprowadzając niepotrzebny szum do danych. W kolejnym kroku wykorzystaliśmy stemming czyli odcięcie przedrostków i przyrostków tak aby pozostawić rdzeń słowa i zgrupować wyrazy z jednej rodziny.

Modelowanie

W tym kroku postanowiliśmy stworzyć dwa modele klasteryzacji: KMeans oraz AgglomerativeClustering

Klastry dobieraliśmy na podstawie wyników z miar silhouette oraz Calińskiego-Harabasza. Następnie stworzyliśmy wizualizacji przy pomocy metody tSNE (z braku alternatywy).

```
from sklearn.cluster import KMeans
import matplotlib.pyplot as plt
from sklearn.manifold import TSNE

def scatter(x, colors):
    palette = np.array(sns.color_palette("hls", 10))

    f = plt.figure(figsize=(8, 8))
    ax = plt.subplot(aspect='equal')
    sc = ax.scatter(x[:,0], x[:,1], lw=0, s=40,
                    c=palette[colors.astype(np.int)])
    plt.xlim(-25, 25)
    plt.ylim(-25, 25)
    ax.axis('off')
    ax.axis('tight')

    txts = []
    for i in range(10):
        xtext, ytext = np.median(x[colors == i, :], axis=0)
        txt = ax.text(xtext, ytext, str(i), fontsize=24)
        txts.append(txt)

    return f, ax, sc, txts
```

```
pip install yellowbrick
```

```
Collecting yellowbrick
  Downloading yellowbrick-1.3.post1-py3-none-any.whl (271 kB)
[?25l[K     |▏                               | 10 kB 13.6 MB/s eta 0:00:01[K     |▎
[?25hRequirement already satisfied: numpy<1.20,≥1.16.0 in /opt/python/envs/default/lib/python3.8/si
Requirement already satisfied: scipy≥1.0.0 in /opt/python/envs/default/lib/python3.8/site-packages (
Requirement already satisfied: cycler≥0.10.0 in /opt/python/envs/default/lib/python3.8/site-packages
Requirement already satisfied: scikit-learn≥0.20 in /opt/python/envs/default/lib/python3.8/site-pack
Requirement already satisfied: matplotlib≠3.0.0,≥2.0.2 in /opt/python/envs/default/lib/python3.8/si
Requirement already satisfied: six in /opt/python/envs/default/lib/python3.8/site-packages (from cycl
Requirement already satisfied: python-dateutil≥2.1 in /opt/python/envs/default/lib/python3.8/site-pa
Requirement already satisfied: pillow≥6.2.0 in /opt/python/envs/default/lib/python3.8/site-packages
Requirement already satisfied: pyparsing≠2.0.4,≠2.1.2,≠2.1.6,≥2.0.3 in /opt/python/envs/default/l
Requirement already satisfied: kiwisolver≥1.0.1 in /opt/python/envs/default/lib/python3.8/site-packa
Requirement already satisfied: joblib≥0.11 in /opt/python/envs/default/lib/python3.8/site-packages (
Requirement already satisfied: threadpoolctl≥2.0.0 in /opt/python/envs/default/lib/python3.8/site-pa
Installing collected packages: yellowbrick
Successfully installed yellowbrick-1.3.post1
[33mWARNING: You are using pip version 21.1; however, version 21.1.2 is available.
You should consider upgrading via the '/opt/python/envs/default/bin/python3 -m pip install --upgrade
Note: you may need to restart the kernel to use updated packages.
```

```
from sklearn.metrics import silhouette_score
from yellowbrick.cluster import KElbowVisualizer


def silhouette(df, i):
    if i == 1:
        model = KMeans(random_state= 0)
    elif i == 2:
        model = Birch(threshold=5)
    elif i == 3:
        model = AgglomerativeClustering()
    cluster_num_seq = range(2, 10)
    scores = []
    for k in cluster_num_seq:
        model.n_clusters = k
        labels = model.fit_predict(df)
        score = silhouette_score(df, labels)
        scores.append(score)

    plt.plot(cluster_num_seq, scores, 'go-')
    plt.xlabel('k')
    plt.ylabel('Silhouette score')
    plt.title('Silhouette plot')
    plt.show()



def calinski_harabasz(df, i):
    if i == 1:
        visualizer = KElbowVisualizer(
        KMeans(random_state= 0), k=(2,10), metric='calinski_harabasz', timings=False, locate_elbow=Fa
    )
    elif i == 2:
        visualizer = KElbowVisualizer(
        Birch(threshold=5), k=(2,10), metric='calinski_harabasz', timings=False, locate_elbow=False
    )
    elif i == 3:
        visualizer = KElbowVisualizer(
        AgglomerativeClustering() , k=(2,10), metric='calinski_harabasz', timings=False, locate_elbow
    )
    else: return
    visualizer.fit(df)
    visualizer.show()
```

```
from sklearn.cluster import Birch
from sklearn.cluster import AgglomerativeClustering

def tSNE_function(df, n, i):
    random_state = 10
    tSNE = TSNE(random_state=random_state, verbose=0)
    books_proj = tSNE.fit_transform(df)
    mod = KMeans(n_clusters=n)
    if i == 2:
        mod = Birch(threshold=5, n_clusters=n)
    if i == 3:
        mod = AgglomerativeClustering(n_clusters=n)
    y = mod.fit_predict(df)

    scatter(books_proj, y)
    plt.show()
```

Model dla początkowej ramki danych

KMeans

Metoda należącą do grupy algorytmów analizy skupień tj. analizy polegającej na szukaniu i wyodrębnianiu grup obiektów podobnych (skupień) . Reprezentuje ona grupę algorytmów niehierarchicznych. Główną różnicą pomiędzy niehierarchicznymi i hierarchicznymi algorytmami jest konieczność wcześniejszego podania ilości skupień.

Miara jakości klasteryzacji

```
silhouette(allBooks, 1)
```

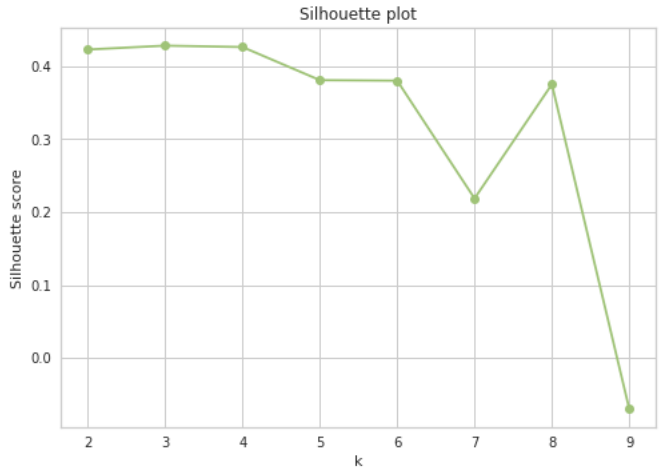


```
findfont: Font family ['sans-serif'] not found. Falling back to DejaVu Sans.
findfont: Font family ['sans-serif'] not found. Falling back to DejaVu Sans.
findfont: Font family ['sans-serif'] not found. Falling back to DejaVu Sans.
```

```
calinski_harabasz(allBooks, 1)
```

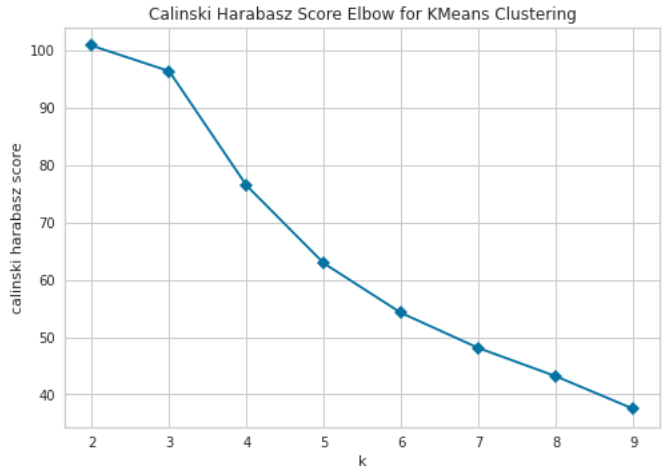

Z miar możemy wywnioskować, że jako optymalną liczbę klastrów należałoby wybrać 2 lub 3 klastry. Narysujmy więc przy pomocy metody tSNE klasteryzacje dla odpowiednio dwóch, trzech oraz ośmiu klastrów

```
tSNE_function(allBooks, 2, 1)
```

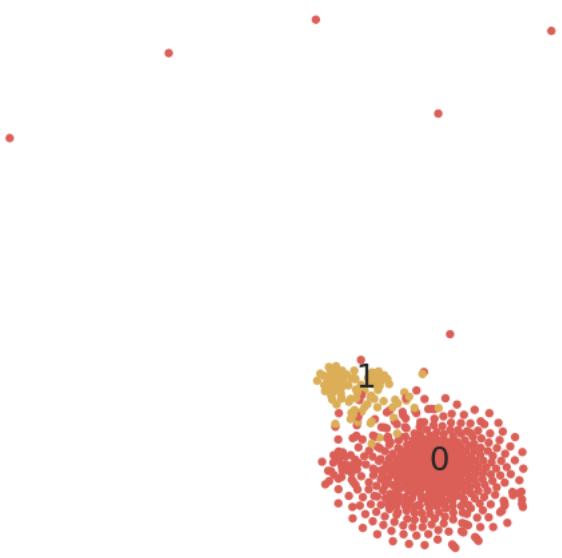

```
findfont: Font family ['sans-serif'] not found. Falling back to DejaVu Sans.
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
```

```
tSNE_function(allBooks, 3, 1)
```

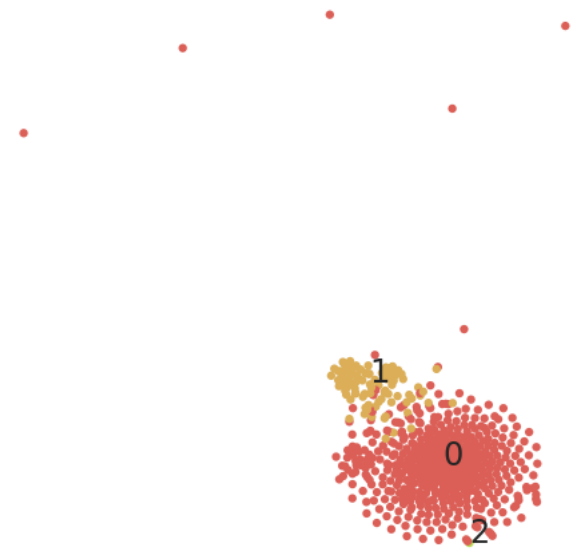


```
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
```

```
tSNE_function(allBooks, 8, 1)
```


```
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
```

AgglomerativeClustering

Przykład modelu należący do metod aglomeracyjnych. Każda obserwacja tworzy na początku jednoelementowy klaster. Następnie pary klastrów są scalane, w każdej iteracji algorytmu łączone są ze sobą dwa najbardziej zbliżone klastry. Tworzone są tzw. „aglomeracje". W tym typie podczas tworzenia klastrów, poruszamy się w górę hierarchii.

Miara jakości klasteryzacji

```
silhouette(allBooks, 3)
```

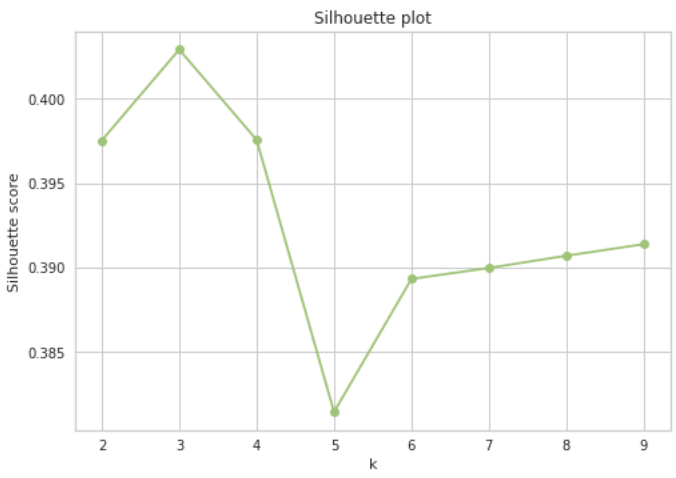


```
calinski_harabasz(allBooks, 3)
```

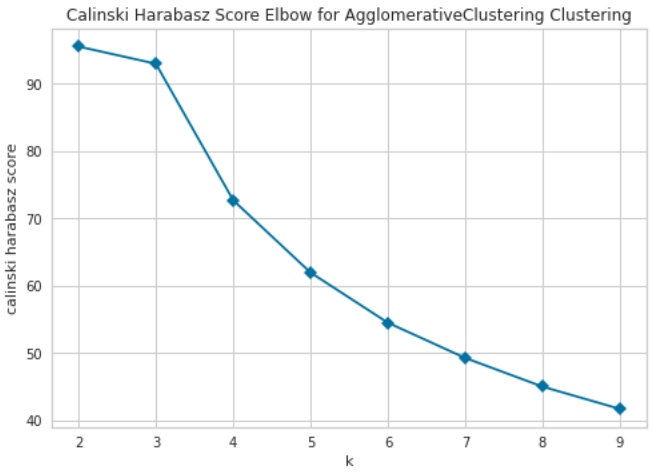

Z miar możemy wywnioskować, że jako optymalną liczbę klastrów należałoby wybrać 2 lub 3 klastry. Narysujmy więc przy pomocy metody tSNE klasteryzacje dla odpowiednio dwóch, trzech oraz ośmiu klastrów

```
tSNE_function(allBooks, 3, 3)
```

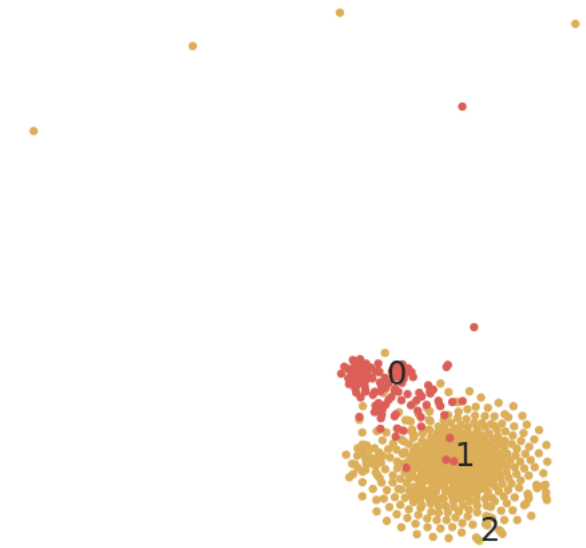


```
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
```

```
tSNE_function(allBooks, 2, 3)
```

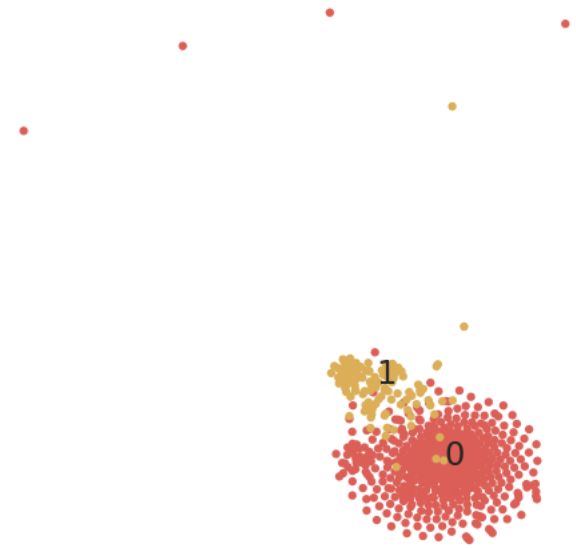


```
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
```

```
tSNE_function(allBooks, 8, 3)
```

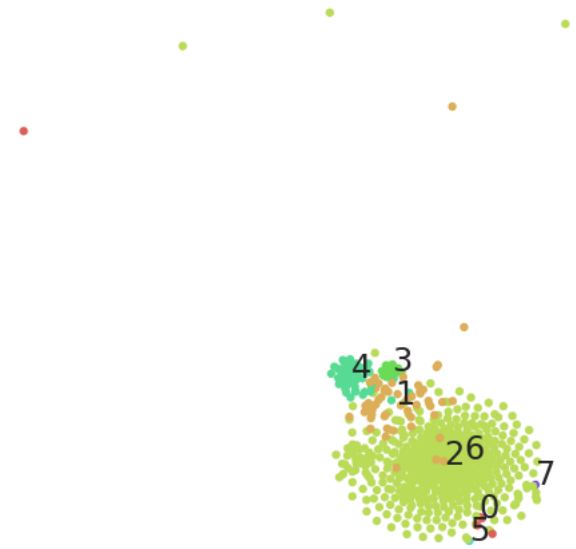


```
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
```

Alternatywna ramka danych

Jednak nawet po takim preprocessingu nasza ramka była bardzo duża a wstępne wyniki modeli nie były zbyt dobre, dlatego postanowiliśmy stworzyć też alternatywną ramkę danych, która będzie zawierała kluczowe zebrane przez nas informacje.

Ramka ta zawiera :

- liczbę wyrazów w każdym rozdziale
- liczbę liter w każdym rozdziale
- liczbę wyrazów z podziałem na części mowy
- oraz polaryzję, czyli liczbę z zakresu <-1,1>, która określa czy tekst jest pozytywny czy negatywny.(-1 oznacza skrajnie negatywny, 1 skrajnie pozytywny). Polaryzacja została zrobiona na dołączonym pełnym tekście rozdziałów, ponieważ badanie tylko pojedynczych słów nie przyniosłoby oczekiwanych rezultatów.

Na tak stworzonej ramce przetestowaliśmy kilka modeli.

```
alternative = pd.read_csv("alternative.csv")
alternative.head()
```

	JJ	NN	NNS	VBP	VBN	VBD	RB	VBG	RBR	VB	...	EX	WDT	FW	WRB	WP$	UH	NNP	Number_
0	9.0	9.0	0.0	1.0	0.0	0.0	2.0	0.0	0.0	1.0	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	298.0
1	8.0	12.0	0.0	0.0	2.0	1.0	0.0	1.0	0.0	1.0	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	107.0
2	29.0	6.0	1.0	6.0	0.0	0.0	3.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	188.0
3	13.0	6.0	0.0	0.0	0.0	6.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	129.0
4	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	15.0

5 rows × 32 columns

Model w przypadku alternatywnej ramki

KMeans

```
silhouette(alternative,1)
```

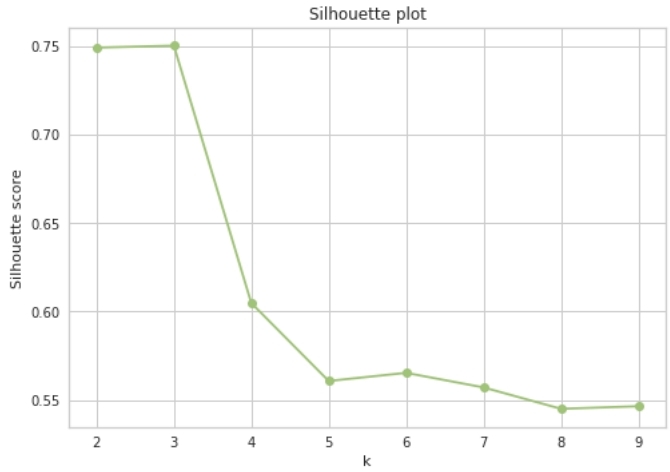


```
calinski_harabasz(alternative,1)
```

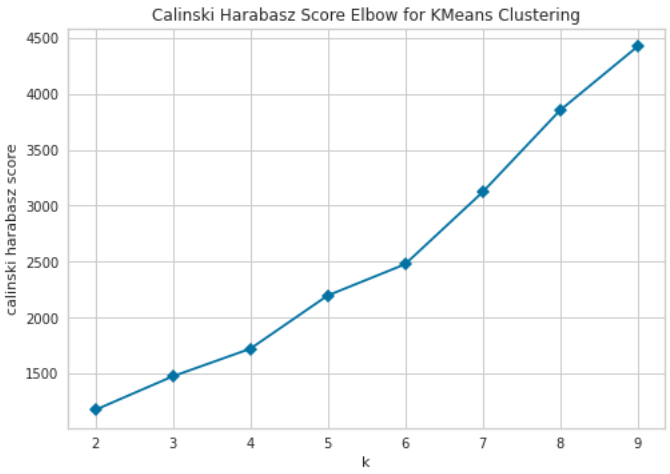


```
tSNE_function(alternative,3,1)
```

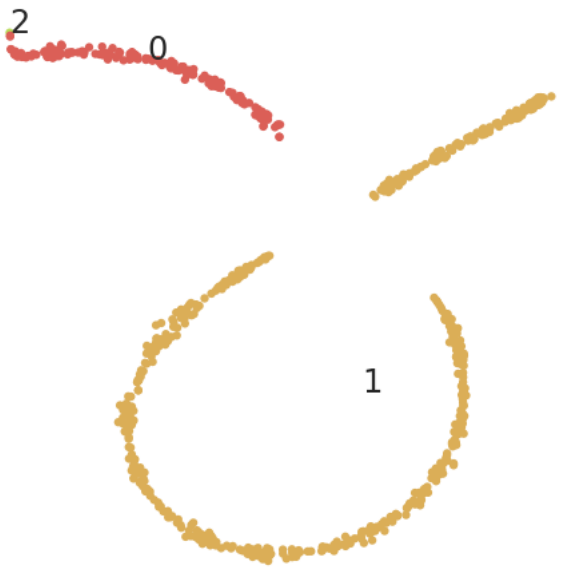


```
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
```

```
tSNE_function(alternative,9,1);
```

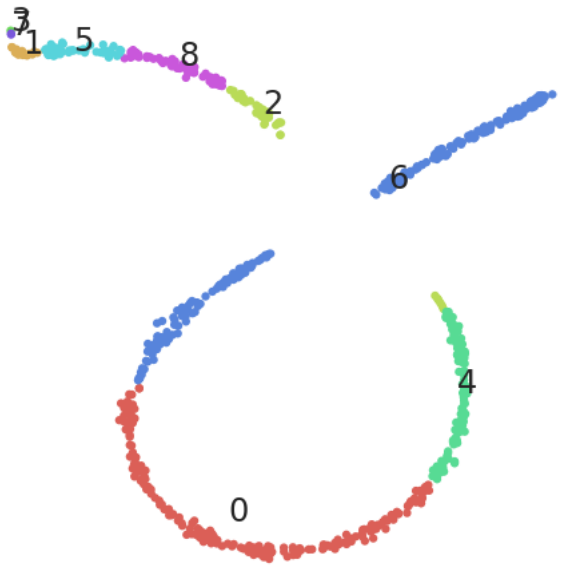


```
posx and posy should be finite values
posx and posy should be finite values
```

```
tSNE_function(alternative,8,1)
```

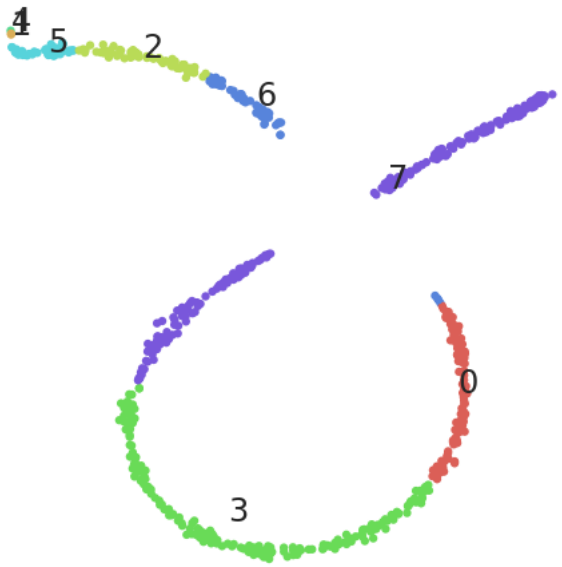


```
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
```

AgglomerativeClustering

```
silhouette(alternative,3)
```


```
calinski_harabasz(alternative,3)
```

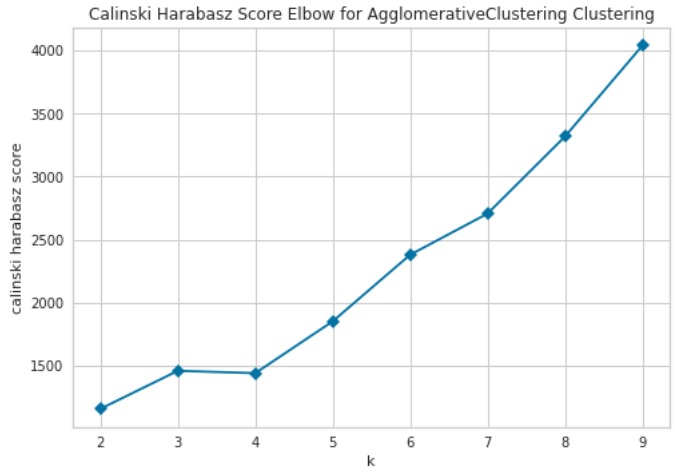

Metoda silhouette wskazała, że optymalną liczbą klastrów, w przypadku metody AgglomerativeClustering, będą 3 klastry, natomiast metoda Calińskiego-Harabasza: 9

```
tSNE_function(alternative,3,3)
```

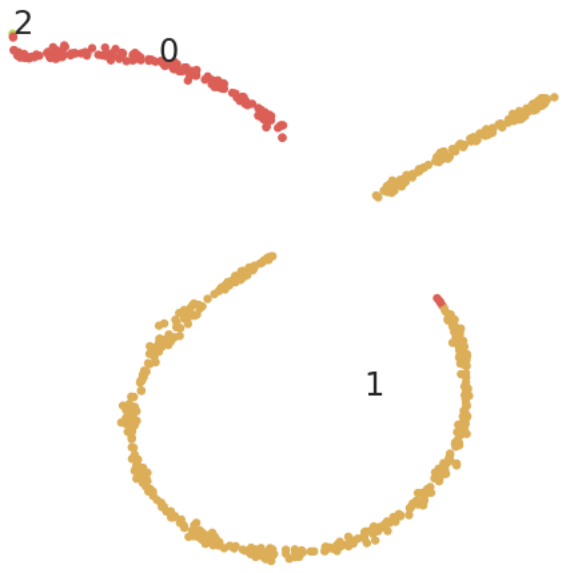


```
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
```

```
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
```

```
#### Model dla
```

```
tSNE_function(alternative,9, 3)
```

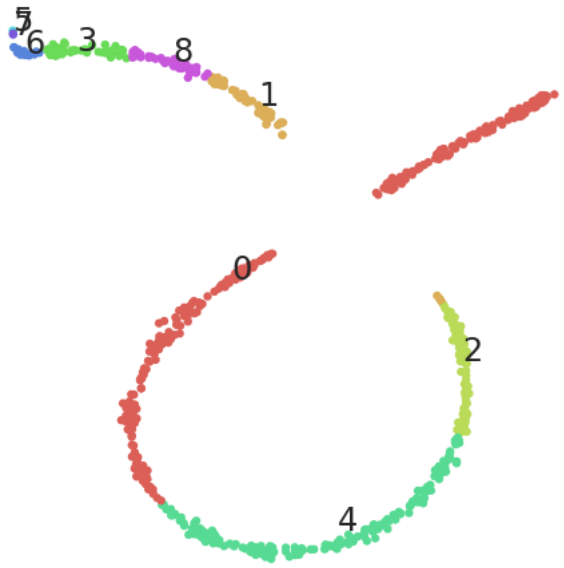


```
posx and posy should be finite values
posx and posy should be finite values
```

```
tSNE_function(alternative,8,3)
```

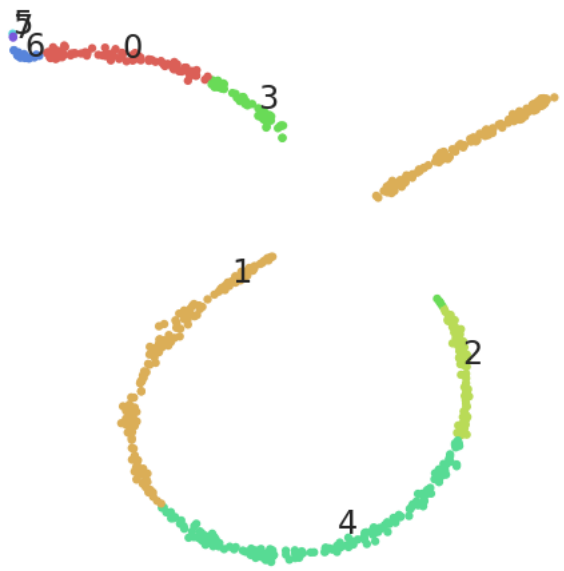


```
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
```

Wyniki wszystkich modeli nie są jednak zadowalająco dobre. Dlatego też skorzystaliśmy jeszcze z metody Word2Vec.

Word2Vec

Jest to metoda, która zamienia słowa na wektory. Powstałe w ten sposób wektory były 300 wymiarowe, co znacząco zmniejszyło rozmiar samej ramki.

Ostatecznie wypróbowaliśmy modele na trzech ramkach:

- tylko ramce alternatywnej
- tylko ramce z wektorami słów
- i na połączonych tych dwóch ramkach.

```
df_vectorized = pd.read_csv("df_vectorized.csv")
df_vectorized.head()
```

	0	1	2	3	4	5	6	7	8	9	...	290	291	292
0	0.041242	0.077604	0.036364	0.066893	-0.134433	0.029582	0.105818	-0.070187	0.071191	0.063919	...	-0.049042	0.110628	-0.0
1	0.095989	0.048129	0.018197	0.085114	-0.013854	-0.018878	0.037942	-0.105520	0.118251	0.051441	...	-0.107915	0.025351	-0.0
2	0.053888	0.052255	-0.036298	0.125530	-0.067041	0.002704	0.061221	-0.062382	0.116936	0.064508	...	-0.081647	0.029627	-0.0
3	0.057171	0.047207	0.022806	0.081331	-0.037910	0.020553	0.113764	0.010203	0.149068	0.085489	...	-0.084059	0.033024	-0.1
4	-0.010864	-0.008883	-0.057831	0.059721	-0.081299	0.038104	0.046274	-0.041307	0.057204	0.053748	...	-0.139047	0.026931	-0.1

5 rows × 300 columns

Model w przypadku wektorów słów

KMeans

```
silhouette(df_vectorized, 1)
```

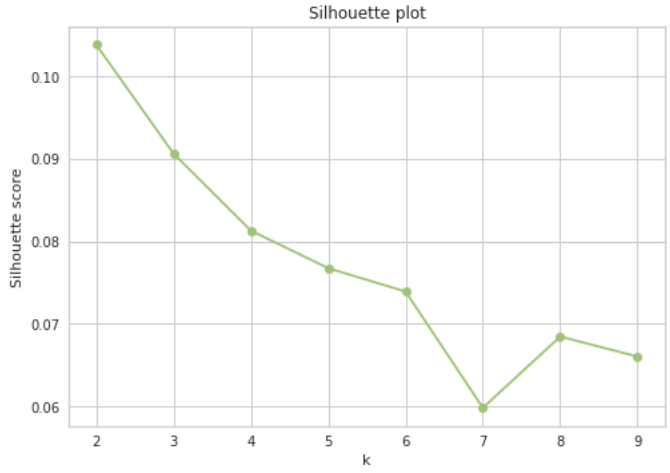


```
calinski_harabasz(df_vectorized, 1)
```

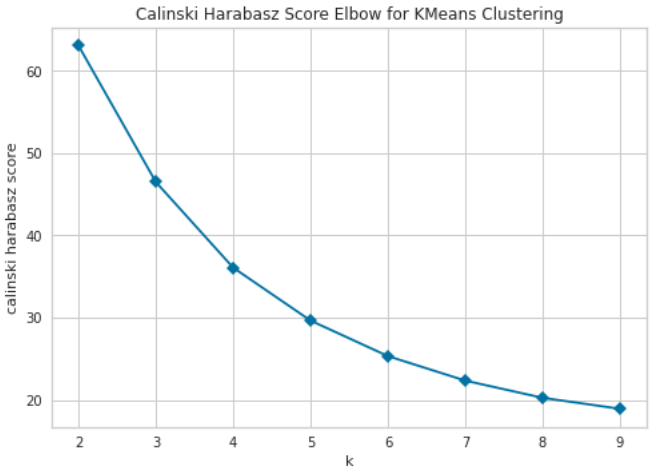

Metoda silhouette oraz Calińskiego-Harabasza wskaxzał, że w tym przypadku optymalną liczbą klastrów będą 2 klastry

```
tSNE_function(df_vectorized, 2, 1)
```

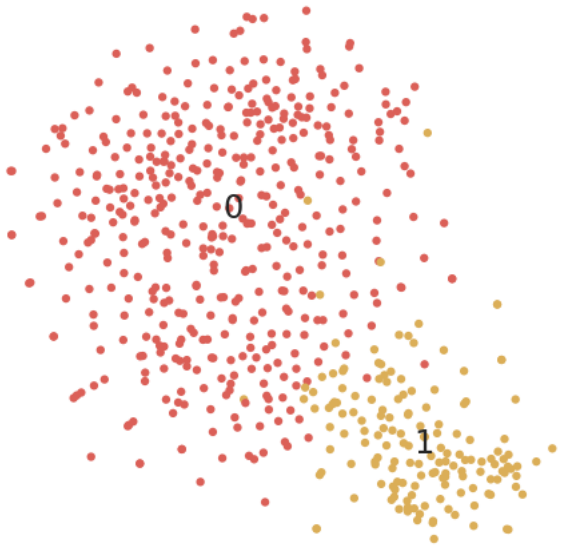


```
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
```

```
tSNE_function(df_vectorized, 8, 1)
```

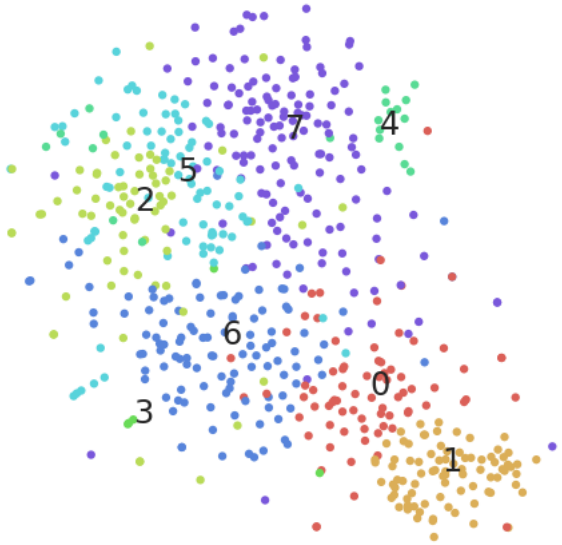


```
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
```

AgglomerativeClustering

```
silhouette(df_vectorized, 3)
```

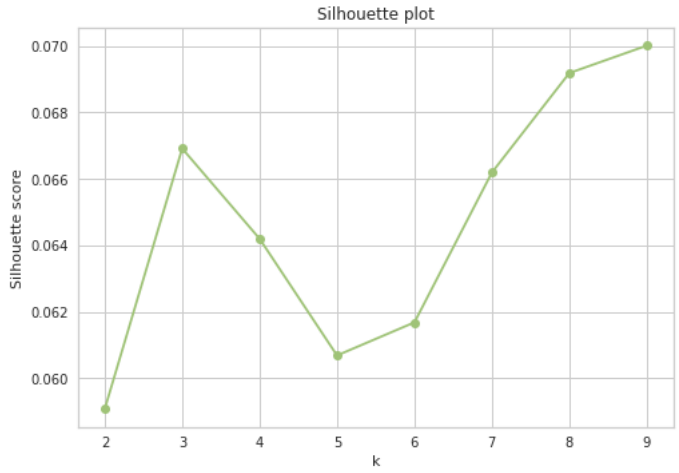


```
calinski_harabasz(df_vectorized, 3)
```

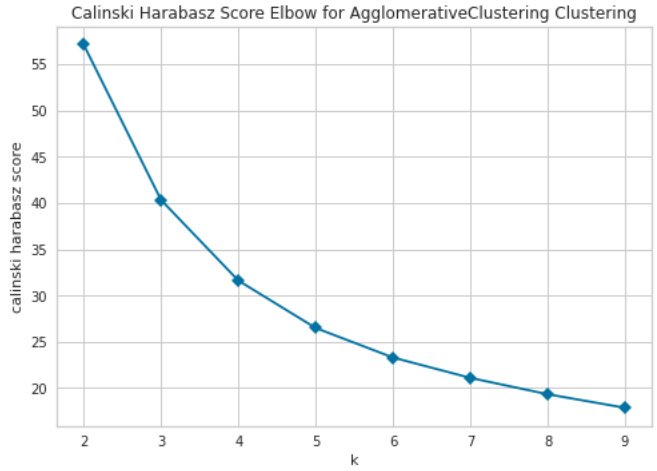

Metoda silhouette wskazała, że optymalną liczbą klastrów, w przypadku metody AgglomerativeClustering, będą 3 klastry, natomiast metoda Calińskiego-Harabasza: 2

```
tSNE_function(df_vectorized, 3, 3)
```

```
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
```

```
tSNE_function(df_vectorized, 2, 3)
```

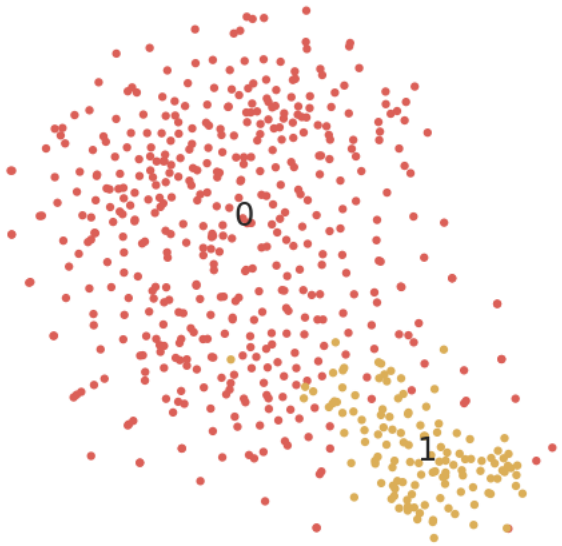


```
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
```

```
tSNE_function(df_vectorized, 8, 3)
```

```
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
```

Model w przypadku wektora słów + alternatywnej ramki

Stwierdziliśmy, że możemy również spróbować połaczyć obie ramki danych, zawierające nieco odmienne informacje, w celu poprawienia predykcji

```
df_merged = pd.concat([df_vectorized, alternative.reindex(df_vectorized.index)], axis=1)
```

KMeans

```
silhouette(df_merged, 1)
```

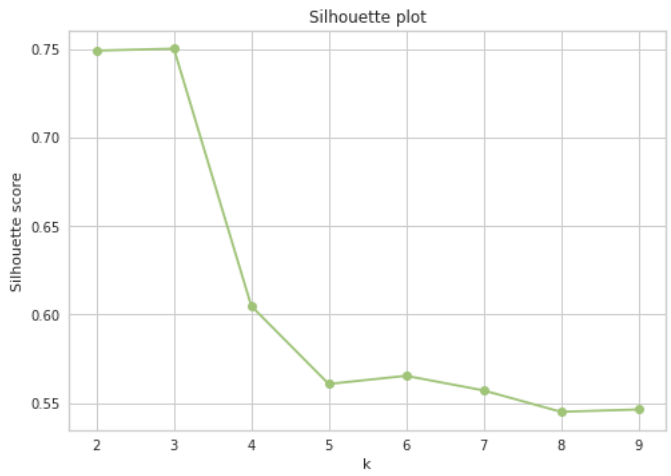


```
calinski_harabasz(df_merged, 1)
```

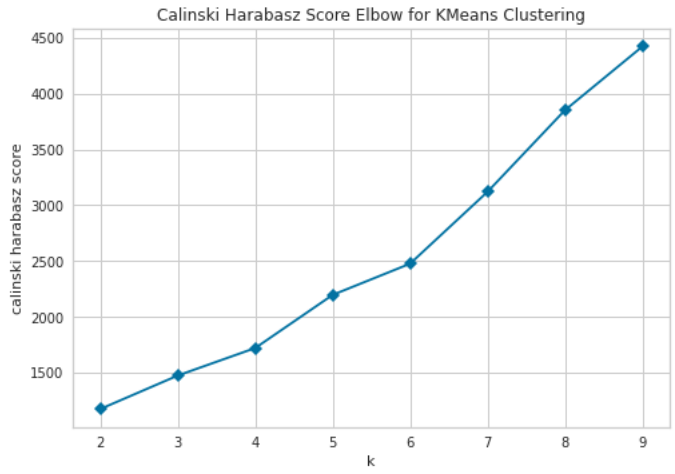

Metoda silhouette wskazała, że optymalną liczbą klastrów, w przypadku metody KMeans, będą 3 klastry, natomiast metoda Calińskiego-Harabasza: 9

```
tSNE_function(df_merged, 3, 3)
```

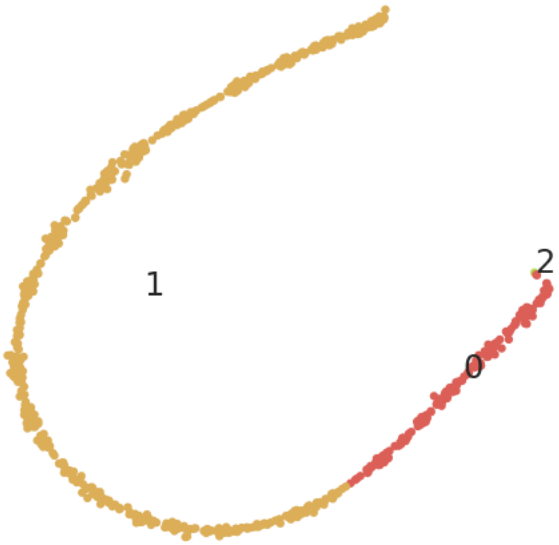


```
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
```

```
tSNE_function(df_merged,9, 3)
```

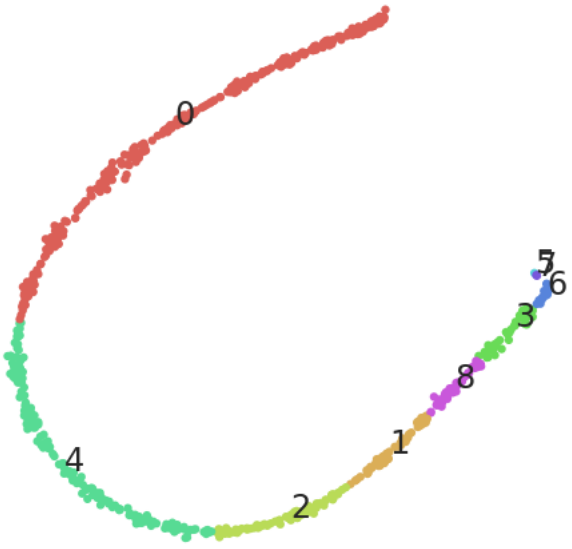


```
posx and posy should be finite values
posx and posy should be finite values
```

```
tSNE_function(df_merged, 8, 3)
```

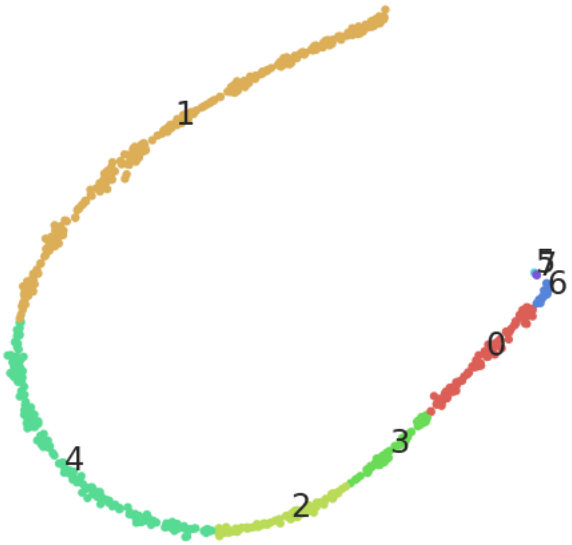


```
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
```

AgglomerativeClustering

```
silhouette(df_merged, 3)
```


```
calinski_harabasz(df_merged, 3)
```

Metoda silhouette wskazała, że optymalną liczbą klastrów, w przypadku metody KMeans, będą 3 klastry, natomiast metoda Calińskiego-Harabasza: 9

```
tSNE_function(df_merged, 3, 3)
```

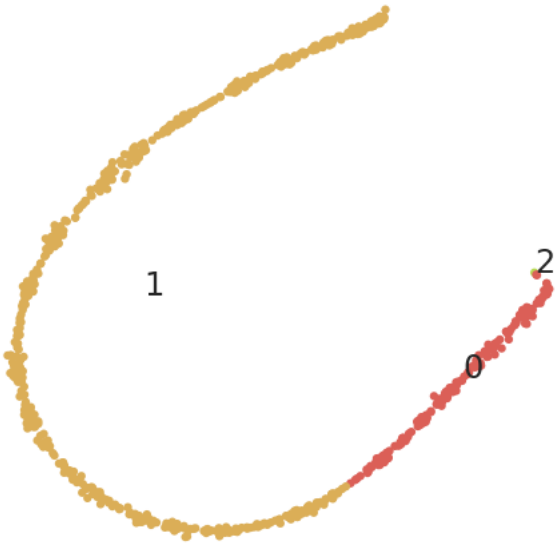


```
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
```

```
tSNE_function(df_merged, 9, 3)
```

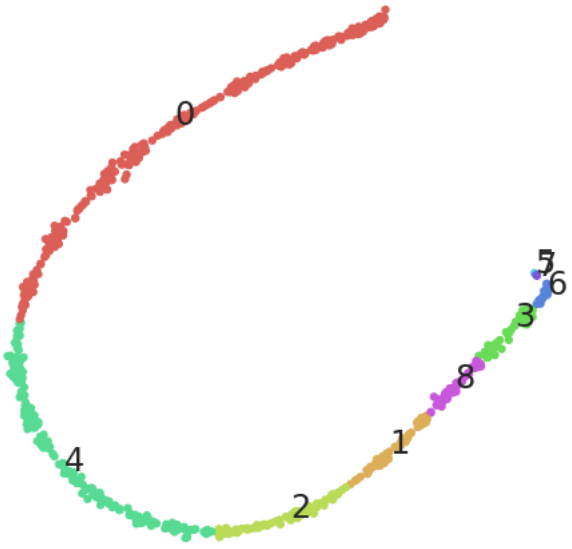


```
posx and posy should be finite values
posx and posy should be finite values
```

```
tSNE_function(df_merged, 8, 3)
```

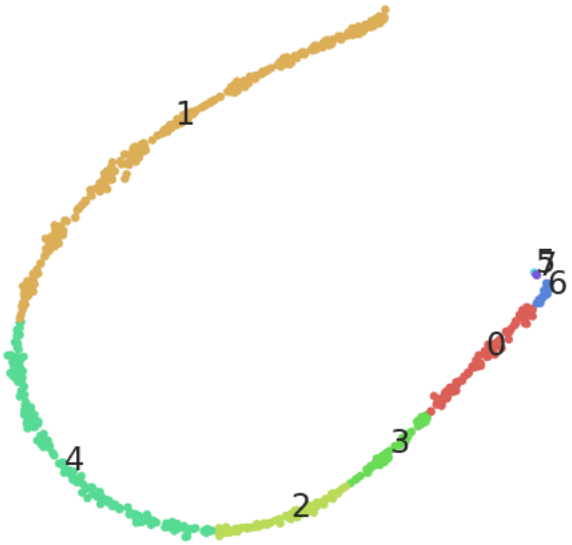


```
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
posx and posy should be finite values
```

Wyniki

Adjusted Rand Index

Do oceny jakości klasterowania użyliśmy miary ARI. Nasze zadanie wymagało użycia Adjusted Rand Index w zamian za Rand Index, bo o ile liczba klastrów była stała, to liczba elementów w klastrach była zmienna i zależała od modelu i danych. Rand Index jest miarą analogiczną do Accuracy, ale stosowaną w zadaniach klasteryzacji. Wartość 0 miary oznacza całkowicie losowy przydział klastrów, a wartość 1 idealny podział danych na klastry.

Najpierw stworzyliśmy listę poprawnych labelów. W tym celu skorzystaliśmy z drugiej ramki danych (AllBooks_baseline_DTM_Labelled.csv), z której wyekstraktowaliśmmy a następnie odpowiedni zformatowaliśmy kolumnę z etykietami.

Pierwotna ramka danych

KMeans

[168]

```
df_raw = pd.read_csv("AllBooks_baseline_DTM_Unlabelled.csv").rename(columns={'# foolishness': 'foolishness'})
kmeans = KMeans(n_clusters=8)
y = kmeans.fit_predict(df_raw)
adjusted_rand_score(true_labels, y)
```

```
0.21685311862163933
```

AgglomerativeClustering

[178]

```
agglomerative_clustering = AgglomerativeClustering(n_clusters=8)
y = agglomerative_clustering.fit_predict(df_raw)
adjusted_rand_score(true_labels, y)
```

```
0.229089356978241
```

Alternatywna ramka danych

KMeans

[215]

```
kmeans = KMeans(n_clusters=8)
y = kmeans.fit_predict(d)
adjusted_rand_score(true_labels, y)
```

```
0.17277497612297507
```

AgglomerativeClustering

[216]

```
agglomerative_clustering = AgglomerativeClustering(n_clusters=8)
y = agglomerative_clustering.fit_predict(d)
adjusted_rand_score(true_labels, y)
```

```
0.20435153827970956
```

Zwektoryzowana ramka danych

KMeans

[160]
```
kmeans = KMeans(n_clusters=8)
y = kmeans.fit_predict(df_vectorized)
adjusted_rand_score(true_labels, y)
```

```
0.21277188769613406
```

AgglomerativeClustering

[164]
```
▶ 0.1s
agglomerative_clustering = AgglomerativeClustering(n_clusters=8)
y = agglomerative_clustering.fit_predict(df_vectorized)
adjusted_rand_score(true_labels, y)
```

```
0.23553917283784076
```

Zmergeowana ramka danych

KMeans

[165]
```
▶ 1.8s
kmeans = KMeans(n_clusters=8)
y = kmeans.fit_predict(df_merged)
adjusted_rand_score(true_labels, y)
```

```
0.17153658223691076
```

AgglomerativeClustering

[167]
```
agglomerative_clustering = AgglomerativeClustering(n_clusters=8)
y = agglomerative_clustering.fit_predict(df_merged)
adjusted_rand_score(true_labels, y)
```

```
0.20435153827970956
```

Podsumowanie

Podsumowując, korzystając tylko z podstawowej ramki wyniki modeli były bardzo słabe, alternatywna ramka zmniejszyły nam wymiarowość ale wyniki nadal nie były zadowalające. To samo dotyczy metody Word2Vec. Nie udało nam się wytrenować modeli, które miałyby wysoką skuteczność.